Univerzitet u Kragujevcu

Domaći zadatak

iz predmeta Sistem za podršku odlučivanju

Tema:

Implementacija regresionih algoritmima nadgledanog učenja

mentori: Ognjen Pavić,
prof. dr. Tijana Geroski,
prof. dr. Nenad Filipović
student: Željko Simić 3vi/2023

Kragujevac 2024.

1 Uvod

Dat je ‘‘`housing.csv`’’ dataset.[1] Namenjen za sagledanje procene vrednosti kuće. U sebi sadrı20640 instanci (uzoraka), a ima u sebi za svaki po 9 kolona atributa (posmatran kao ulazna vrednost):

- `longitude` - ugao zastupljene lokacije naspram zapada (većom vrednošću on je dalje) i ekvatora planete Zemlje, $[-180, 180]$;
- `latitude` - ugao zastupljene lokacije naspram severa (većom vrednošću on je dalje) i meridijana planete Zemlje $[-180, 180]$;
- `housing_median_age` - stopa osrednje godine kuće, kontinualna vrednost;
- `total_rooms` - ukupan broj soba, numerička vrednost;
- `total_bedrooms` - ukupan broj spavaćih soba, numerička vrednost;
- `population` - broj ljudi u naselju, numerička vrednost;
- `households` - broj domaćinstava u naselju, numerička vrednost;
- `median_income` - stopa osrednjeg prihoda u naselju, numerička vrednost;
- `ocean_proximity` - udaljenost lokacije od najbliže lokacije mora, kategorička vrednost.

i 1 ciljnu vrednost (posmatran kao izlaznu vrednost):

- `median_house_value` - stopa osrednjeg vrednovanja kuće u USD valuti;

2 Metodologija

Uz tekst seminarskog rada je priložen izvorni kod (na putanji `./src/main.py`) koji će se ovde sagledati. Implementacija 1. u sebi sadrži deklaracije uvedenih modula iz kojih će biti pozivane njihove komponente u daljem radu (praktično realizovanje teorijskog rada na ovu temu[2]). Korišćen je objektni tip podataka `pandas.DataFrame`[3] kojim će biti urađeno strukturno skladištenje (sa metodom `pd.read_csv(putanja_csv_fajla_skupa_podataka)`) i manipulisano elementima skupa podataka koji je bio pomenut u uvodu. Biće izvršeno zaobilaženje prikaza obaveštenja na standardnom izlazu greške, predprocesiranje u kom spada eliminisanje nedostajućih instanci, pokušaj eliminacije duplikata, enkodiranje `ocean_proximity` atributa (da bi bio prikladan za dalji rad sa regresijom iz vrednosti tipa string-a u broj)[4], skaliranje vrednosti features-a `MinMaxScaler`-om (po pretpostavci da nam normalna distribucija, uglavnom, nije zastupljena i obavljena je zarad skupljanja svih vrednosti na gomilu u početnoj oblasti $[0, 1]$)[5], podela skupa podataka uz `train_test_split(...)` na trening i test skupove podataka po nekoj razmeri $8 : 2$ za ulazne i izlazne vrednosti klasifikacija.[6]

```

import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np
from sklearn.preprocessing import LabelEncoder
from sklearn.preprocessing import MinMaxScaler
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.tree import DecisionTreeRegressor
from sklearn.ensemble import RandomForestRegressor

from sklearn.svm import SVR
from sklearn.metrics import r2_score
import warnings
warnings.filterwarnings("ignore")

...
dataframe = pd.read_csv('./housing.csv')
print("==================")
print("Nedostajuce vrednosti:")
print(dataframe.isnull().sum())
df1 = dataframe[dataframe['total_bedrooms'].notnull()]

print("==================")
duplikati = df1[df1.duplicated()]
if len(duplikati) == 0:
  print("Nema duplikata")
else:
  print(duplikati)
print("==================")

df1['ocean_proximity']= LabelEncoder().fit_transform(df1['ocean_proximity'])
...
y1 = df1['median_house_value']
x1 = df1[["longitude","latitude","housing_median_age","total_rooms","
    total_bedrooms","population","households","median_income","
    ocean_proximity"]]
sc = MinMaxScaler()
x1_scalled = sc.fit_transform(x1)

```

```

X_train, X_test, y_train, y_test = train_test_split(x1_scalled, y1,
    test_size = 0.2)
```

Implementacija 1: Predprocesiranje podataka i navođenje modula koji će se koristiti

Na izlazu 1. je prikazano da 207 instanci ima nedostajuće vrednosti i oni će biti eliminisani nadalje, a takođe je prikazano da duplikata nije takođe bilo.

```
==================
Nedostajuce vrednosti:
longitude               0
latitude                0
housing_median_age      0
total_rooms             0
total_bedrooms        207
population              0
households              0
median_income           0
median_house_value      0
ocean_proximity         0
dtype: int64
==================
Nema duplikata
==================
```

Izlaz 1: Nedostajuće vrednosti i duplikati

U implementaciji 2. vrši se generisanje slika 1. (za korelaciju među features-ima po verovatonosnoj distributivnoj funkciji (PDF) na target vrednost `Purchased`), 2. (za distribuciju naspram feature-a `Age` i target vrednosti), 3. (za distribuciju naspram feature-a `EstimatedSalary`). Ovo sve je obavljeno uz metode `seaborn.pairplot` za sliku 1.[7] i `seaborn.displot` za slike 2. i 3.[8]

```
sns.pairplot(dataframe, palette="Spectral", hue="median_house_value", dropna
    =True)
plt.show()
```

Implementacija 2: Navođenje načina vizuelizacija za sliku `1.`

Ovaj deo koji sledi važi samo za vrednosti koje još uvek nisu skalirane maločas pomenutim postupkom skaliranja.

Na slici 1. je moguće uočiti da PDF za feature `longitude` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [-125, -122] i [-120, -106] najviše za osrednju vrednost kuće od 500000$.

Za PDF `longitude` naspram `latitude` po `median_house_value` može se videti zastupljenost [-116, -114] naspram [30,35] i [-124, -120] naspram [40, 45] za 300000$ i naniže, a za više osrednje vrednosti kuće na [-122, -114] naspram [30,35].

Za PDF `longitude` naspram `house_median_age` po `median_house_value` može se videti zastupljenost [-116, -114] naspram [0,75] i [-124, -120] naspram [0, 75] za 300000$ i naniže, a za više osrednje vrednosti kuće na [-122, -116] naspram [0,75].

Za PDF `longitude` naspram `total_rooms` po `median_house_value` može se videti zastupljenost [-116, -114] naspram [0,25000] i [-124, -120] naspram [0, 25000] za 300000$ i naniže, a za više osrednje vrednosti kuće na [-122, -116] naspram [0,25000].

Za PDF `longitude` naspram `total_bedrooms` po `median_house_value` može se videti zastupljenost [-116, -114] naspram [0,25000] i [-124, -120] naspram [0, 5000] za 300000$ i naniže, a za više osrednje vrednosti kuće na [-122, -116] naspram [0,5000].

Za PDF `longitude` naspram `population` po `median_house_value` može se videti zastupljenost [-116, -114] naspram [0,10000] i [-124, -120] naspram [0,10000] za 300000$ i naniže, a za više osrednje vrednosti kuće na [-122, -114] naspram [0,10000].

Za PDF `longitude` naspram `households` po `median_house_value` može se videti zastupljenost [-116, -114] naspram [0,1000] i [-124, -120] naspram [0,1000] za 300000$ i naniže, a za više osrednje vrednosti kuće na [-122, -114] naspram [0,5000].

Za PDF `longitude` naspram `median_income` po `median_house_value` može se videti zastupljenost [-116, -114] naspram [30,35] i [-124, -120] naspram [0, 10] za 300000$ i naniže, a za više osrednje vrednosti kuće na [-122, -114] naspram [0,10], osim za 500000$ na [-119, -116] naspram [10, 20].

PDF za `latitude` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [32, 34] i [36,38] naniže za osrednju vrednost kuće od 500000$.

Za PDF `latitude` naspram `house_median_age` po `median_house_value` može se videti zastupljenost [38, 42] naspram [0, 50] za 300000$ i naniže.

Za PDF `latitude` naspram `total_rooms` po `median_house_value` može se videti zastupljenost [38, 42] naspram [0,10000] za 300000$ i naniže.

Za PDF `latitude` naspram `total_bedrooms` po `median_house_value` može se videti zastupljenost [38, 42] naspram [0,2000] za 300000$ i naniže.

Za PDF `latitude` naspram `population` po `median_house_value` može se videti zastupljenost [38, 42] naspram [0,10000] za 300000$ i naniže.

Za PDF `latitude` naspram `households` po `median_house_value` može se videti zastupljenost [38, 42] naspram [0,2000] za 300000$ i naniže.

Za PDF `latitude` naspram `median_income` po `median_house_value` može se videti zastupljenost [38, 42] naspram [0,10] za 300000$ i naniže, a za 500000$ [37, 38] naspram [10,15] i [33,35] naspram [10,15].

PDF za `house_median_age` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [0, 50] naniže za osrednju vrednost kuće od 500000$.

Za PDF `house_median_age` naspram `total_rooms` po `median_house_value` može se videti zastupljenost [0, 40] naspram [0, 10000] za 300000$ i naniže.

Za PDF `house_median_age` naspram `total_bedrooms` po `median_house_value` može se videti zastupljenost [10, 50] naspram [0, 2000] za 300000$ i naniže.

Za PDF `house_median_age` naspram `population` po `median_house_value` može se videti zastupljenost [5,50] naspram [0, 5000] za 300000$ i naniže.

Za PDF `house_median_age` naspram `households` po `median_house_value` može se videti zastupljenost [5, 50] naspram [38, 42] za 300000$ i naniže.

Za PDF `house_median_age` naspram `median_income` po `median_house_value` može se videti zastupljenost [0, 50] naspram [0, 10] za 300000$ i naniže, a za 500000$ na [10,20] naspram [0, 50].

PDF za `total_rooms` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [0, 10000] najviše za osrednju vrednost kuće od 400000$, pa za sve ostale u tom sličnom domenu.

Za PDF `total_rooms` naspram `total_bedrooms` po `median_house_value` može se videti zastupljenost [0, 10000] naspram [0, 2000] za 300000$ i naniže.

Za PDF `total_rooms` naspram `population` po `median_house_value` može se videti zastupljenost [0, 10000] naspram [0, 10000] za 300000$ i naniže.

Za PDF `total_rooms` naspram `households` po `median_house_value` može se videti zastupljenost [0, 10000] naspram [0, 2000] za 300000$ i naniže.

Za PDF `total_rooms` naspram `median_income` po `median_house_value` može se videti zastupljenost [0, 20000] naspram [0, 5] za 300000$ i naniže, a za 500000$ na [0,10000] naspram [10, 20].

PDF za `total_bedrooms` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [0, 1000] najviše za osrednju vrednost kuće od 500000$, pa za sve ostale u tom sličnom domenu.

Za PDF `total_bedrooms` naspram `population` po `median_house_value` može se videti zastupljenost [0, 5000] naspram [0, 10000] za 300000$ i naniže.

Za PDF `total_bedrooms` naspram `households` po `median_house_value` može se videti zastupljenost [0, 5000] naspram [0, 5000] za 300000$ i naniže.

Za PDF `total_bedrooms` naspram `median_income` po `median_house_value` može se videti zastupljenost [0, 5000] naspram [0, 5] za 300000$ i naniže, a za 500000$ na [0,2000] naspram [10, 18].

PDF za `population` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [0, 5000] najviše za osrednju vrednost kuće od 500000$, pa za sve ostale u tom sličnom domenu.

Za PDF `population` naspram `households` po `median_house_value` može se videti zastupljenost [0, 5000] naspram [0, 5000] za 300000$ i naniže, a za 500000$ na [0,2000] naspram [10, 18].

Za PDF `population` naspram `median_income` po `median_house_value` može se videti zastupljenost [0, 5000] naspram [0, 5] za 300000$ i naniže, a za 500000$ na [0,2000] naspram [10, 18].

PDF za `households` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [0, 5000] najviše za osrednju vrednost kuće od 500000$, pa za sve ostale u tom sličnom domenu.

Za PDF `households` naspram `median_income` po `median_house_value` može se videti zastupljenost [0, 4000] naspram [0, 5] za 300000$ i naniže, a za 500000$ na [0,2000] naspram [10, 18].

PDF za `median_income` `median_house_value` vrednosti ukazuje na zastupljenost po toj komponenti lokacije na domenu [0, 2] za osrednju vrednost kuće od 500000$, a na domenu [10,15] najviše za osrednju vrednost kuće od 100000$, pa za sve ostale u tom sličnom domenu.

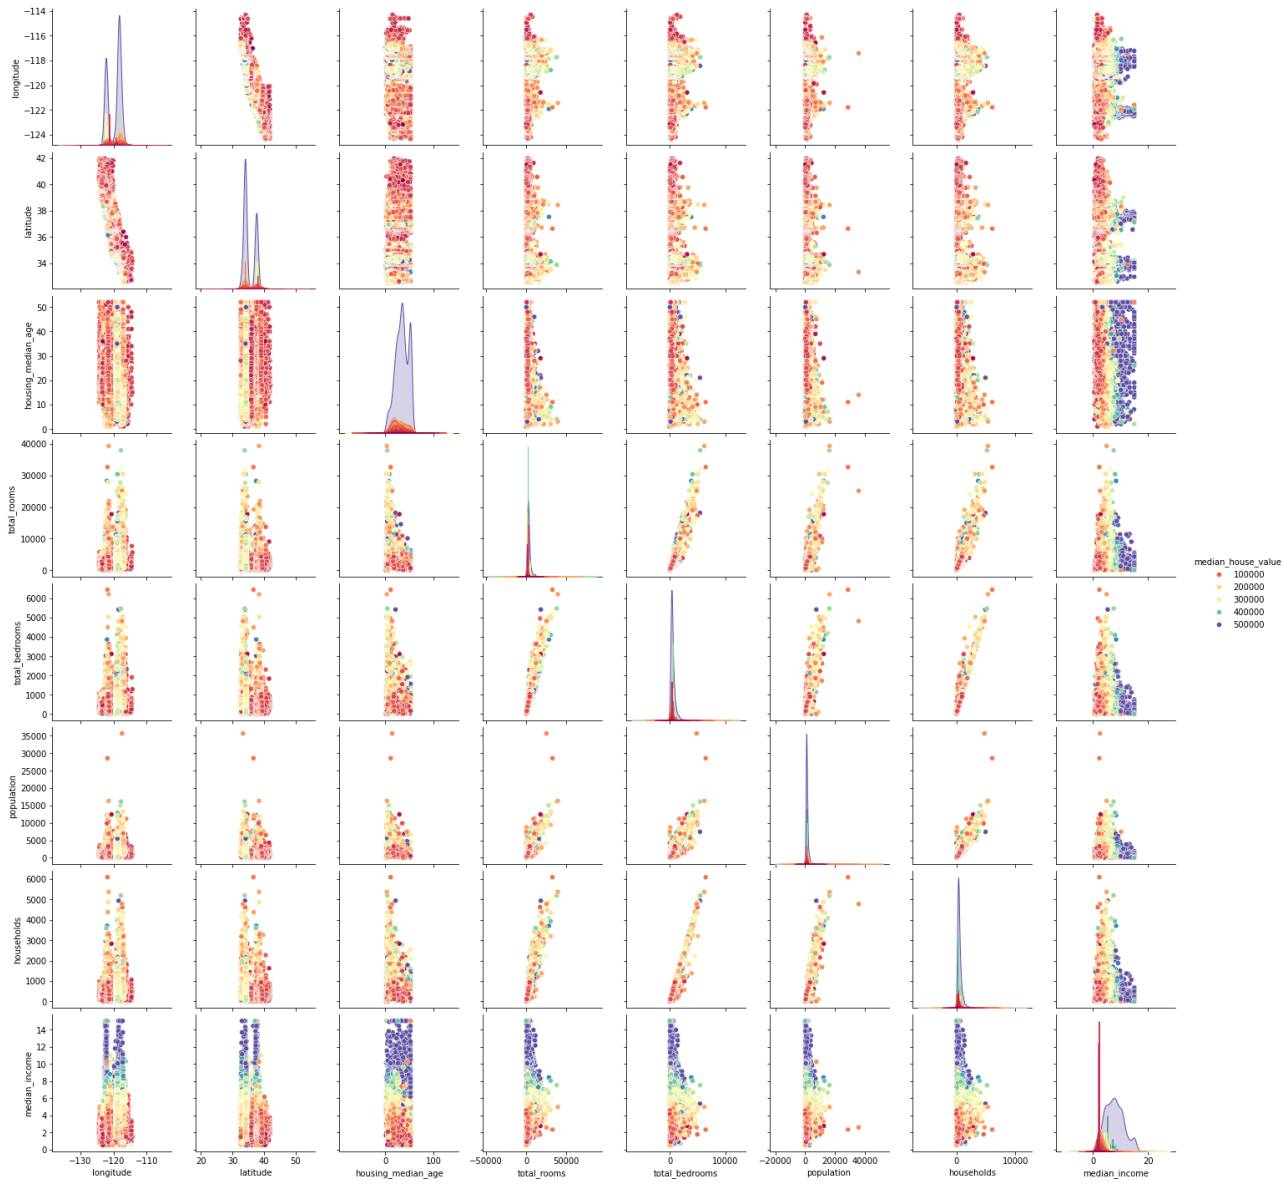

Slika 1: Vizuelizacija za korelaciju među features-ima po verovatonosnoj distributivnoj funkciji (PDF) na target vrednost `median_house_value`

3 Metodologija

U implementaciji 3. dat je postupak ispisa evaluacije (korena) središnje kvadratne greške koji će se prikazivati. Ova funkcija će se nadalje primenjivati u daljem radu, uglavnom, a pritom će se prikazivati *R2 score*.

```
def evaluate(y_pred, y_test,name):

    square_error=np.array(y_test-y_pred)
    square_error=np.power(square_error,2)
    square_error=np.sum(square_error)

    mean_square_error=square_error/len(y_pred)

    root_mean_square_error=np.sqrt(mean_square_error)

    print(name)
    print('mean square error: ' + str(round(mean_square_error,2)))
    print('root mean square error: ' + str(round(root_mean_square_error,2)))
    print()

    return mean_square_error,root_mean_square_error
```

Implementacija 3: Postupak ispisa evaluacije (korena) središnje kvadratne greške

3.1 Jednostavna linearna regresija (SLR)

Vršiće se treniranja i predikcije naspram svakog feature-a ponaosob, pošto ovaj algoritam[9] radi sa samo 1 feature-om, a takođe ovaj algoritam nema nikakvih hiperparametara.

U ovom slučaju u implementaciji 4. radi se evaluacija naspram feature-a, usresređujući se na ciljnu vrednost, za svaku je ispisan kranji MSE i RMSE. Moguće je uočiti da je dat najviše značaj treniranju i predikciji nad feature-om `median_income`. Za taj feature dat je i R2 score i iscrtan grafik za pravu regresije među instancama, uzimanjem dveju tačaka naspram koordinate najmanjeg ulaznog parametara i njegovom multiplikacijom odnosa 1.01, pravljenja niza od 10 elemenata i formiranjem niza y elemenata prema nagibu i odsečkom na y-osi.

```
model = LinearRegression()

model.fit(X_train[:,0].reshape(-1,1),y_train)
predicted = model.predict(X_test[:,0].reshape(-1,1))

mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
    longitude")
########################################
model.fit(X_train[:,1].reshape(-1,1),y_train)
predicted = model.predict(X_test[:,1].reshape(-1,1))

mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
    latitude")
########################################
model.fit(X_train[:,2].reshape(-1,1),y_train)
predicted = model.predict(X_test[:,2].reshape(-1,1))

mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
    housing_median_age")
########################################
model.fit(X_train[:,3].reshape(-1,1),y_train)
predicted = model.predict(X_test[:,3].reshape(-1,1))
```

```
20
21 mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
       total_rooms")
22 ########################################
23 model.fit(X_train[:,4].reshape(-1,1),y_train)
24 predicted = model.predict(X_test[:,4].reshape(-1,1))
25
26 mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
       total_bedrooms")
27 ########################################
28 model.fit(X_train[:,5].reshape(-1,1),y_train)
29 predicted = model.predict(X_test[:,5].reshape(-1,1))
30
31 mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
       population")
32 ########################################
33 model.fit(X_train[:,6].reshape(-1,1),y_train)
34 predicted = model.predict(X_test[:,6].reshape(-1,1))
35
36 mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
       households")
37 ########################################
38 model.fit(X_train[:,7].reshape(-1,1),y_train)
39 predicted = model.predict(X_test[:,7].reshape(-1,1))
40
41 mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
       median_income")
42
43 print(f"R2 score: {r2_score(y_test, predicted)}")
44 plt.figure()
45 plt.title('regression visualisation')
46 plt.scatter(X_test[:,7], y_test, color='black')
47 plt.plot(X_test[:,7], predicted)
48 plt.show()
49
50 plt.figure()
51 plt.title('linear model visualisation')
52 plt.scatter(X_test[:,7], y_test, color='black')
53 coefficients = model.coef_
54 intercept = model.intercept_
55 k = coefficients
56 n = intercept
57
58 line_x = np.arange(min(X_train[:,7]), 1.01*max(X_train[:,7]), (max(X_train
       [:,7])- min(X_train[:,7]))/10)
59 line_y = k * line_x + n
60 plt.plot(line_x, line_y, color='red')
61 plt.show()
62 ########################################
63 model.fit(X_train[:,8].reshape(-1,1),y_train)
64 predicted = model.predict(X_test[:,8].reshape(-1,1))
65
66 mse,rmse=evaluate(predicted, list(y_test), "Simple linear regresion over
       ocean_proximity")
```

Implementacija 4: Postupak evaluacija naspram svakog feature-a ponaosob.

3.2 Višestruka linearna regresija (MLR)

Vrši se instanciranje klase modula `LinearRegression`, vrši se obuka nad trening skupom, ispisuju ste statistike greške MSE, RMSE, R2 score i iscrtava se grafik linearne regresije kao i ranije. Hiperparametara kod ovog algoritma nema.

```
model = LinearRegression()
model.fit(X_train,y_train)
predicted = model.predict(X_test)

mse,rmse=evaluate(predicted, list(y_test), "Multiple linear regresion")
print(f"R2 score: {r2_score(y_test, predicted)}")

plt.figure()
plt.title('linear model visualisation')
plt.scatter(X_test, y_test, color='black')
coefficients = model.coef_
intercept = model.intercept_
k = coefficients
n = intercept

line_x = np.arange(min(X_train), 1.01*max(X_train), (max(X_train)- min(
    X_train))/10)
line_y = k * line_x + n
plt.plot(line_x, line_y, color='red')
plt.show()
```

Implementacija 5: Postupak MLR-a

3.3 Polinomijalna linearna regresija (PLR)

`PolynomialFeatures`[10] u kombinaciji sa `LinearRegression`. Korišćen je algoritam za usklađivanje za rad sa polinomijalnim linearnim regresijama. Postavljen je inicijalni stepen polinoma koji će izgraditi aproksimiranu krivu za ulazne vrednosti trening skupa koji će biti prilagođeni da rade nad takvim tipom algoritma. Formira se niz tačaka za grafik na koji će se iscrtati kriva i tačke instanci koje će biti razdvojene tom krivom. Predikcijom dobijaju se koeficijenti elemenata svakog stepena polinoma, generiše se isti niz kao za pravu za ulazne vrednosti (prvog feature-a) trening skupa, a zatim se formira novi nizovi gde su svi elementi stepenovani na kvadratni i kubni stepen. Takođe je uzet u obzir odsečak sa y-osom. Ovde je uzet u obzir `households` feautre kao prikaz instanci, koji po mom mišljenju ima doličan prikaz razdvajanja.

```
polynomialRegression = PolynomialFeatures(degree = 3)
X_train_poly = polynomialRegression.fit_transform(X_train)
X_test_poly = polynomialRegression.transform(X_test)
model = LinearRegression()
model.fit(X_train_poly, y_train)

predicted = model.predict(X_test_poly)

mse, rmse = evaluate(list(y_test), predicted, 'polynomial_regression')
print(f"R2 score: {r2_score(y_test, predicted)}")

plt.figure()
plt.title('polynomial regr visualization')
plt.scatter (X_test[:,6], y_test, color="black")

coefficients = model.coef_
```

```
intercept = model.intercept_
k1 = coefficients[0]
k2 = coefficients[1]
k3 = coefficients[2]
n = intercept

X = X_train[:,0]
line_x1 = np.arange(min(X),
          max(X) * 1.01,
          (max(X) - min(X)) / 10)
line_x2 = line_x1 ** 2
line_x3 = line_x1 ** 3

line_y3 = k1*line_x1 + k2*line_x2 + k3*line_x3 + n

plt.plot(line_x1, line_y3, color="red")
plt.show()
```

Implementacija 6: Postupak PLR-a

3.4 Regresija stabla odlučivanja

Postupak regresije stabla odlučivanja[11] bez i sa optimizacijom hiperparametrima je obavljen obukom nad trening skupom podataka, kao i predikcijom nad test skupom podataka, ispisan je takođe MSE, RMSE, R2 score. Korišćeni hiperparametri su:

- `splitter` - koji je implicitno postavljen na vrednost best i naznačava strategiju kojom će se vršiti podele grananjima;
- `max_depth` - koji implicitno nema nikakvu vrednost, ističe se kolika je dubina stabla koje se generiše;
- `min_samples_leaf` - implicitna vrednost mu je 1, a označava koliko mora najmanje instanci sadržati čvor lista stabla;
- `min_weight_fraction_leaf` - implicitna vrednost 0, a označava minimalno nephodnu sumu težina svih uzoraka u listu stabla;
- `max_features` - implicitno nema kriterijuma, ali kad ima njime se zaključuje na koiji način, kojom funkcijom će se sagledati podela naspram broja feature vrednosti.
- `max_leaf_nodes` - implicitno nema postavljen zahtevajući kriterijum što naznačava da je ograničenje broja čvorova ∞, a rast stabla će se obavljati u najbolji-prvo maniru.

Optimizacija hiperparametrima[12] će se obaviti i nakon svake evaluacije algoritmom istaći će se najbolji ishodujući model sa njegovim hiperparametrima. Takođe je obavljen stratifikovan cross-validation postupak.

```
decisionTreeRegressor=DecisionTreeRegressor()
decisionTreeRegressor.fit(X_train, y_train)
predicted = decisionTreeRegressor.predict(X_test)
mse, rmse = evaluate(list(y_test), predicted, 'decision tree')
print(f"R2 score: {r2_score(y_test, predicted)}")

print("-------------------")
# https://www.nbshare.io/notebook/312837011/Decision-Tree-Regression-With-
    Hyper-Parameter-Tuning-In-Python/
```

```
params={"splitter":["best","random"],
            "max_depth" : [1,3,5,7,9,11,12],
            "min_samples_leaf":[1,2,3,4,5,6,7,8,9,10],
            "min_weight_fraction_leaf"
    :[0.1,0.2,0.3,0.4,0.5,0.6,0.7,0.8,0.9],
            "max_features":["auto","log2","sqrt",None],
            "max_leaf_nodes":[None,10,20,30,40,50,60,70,80,90]}

modelGrid=GridSearchCV(DecisionTreeRegressor(),param_grid=params,cv=5)
modelGrid.fit(X_train,y_train)
modelBest = modelGrid.best_estimator_
predicted=modelBest.predict(X_test)
mse,rmse=evaluate(predicted, list(y_test), "decision tree with
    hyperparameter optimization")
print(f"R2 score: {r2_score(y_test, predicted)}")
print('best params after grid search: ')
print(modelGrid.best_params_)
```

Implementacija 7: Postupak regresije stabla odlučivanja bez i sa optimizacijom hiperparametrima

3.5 Regresija slučajne šume

Postupak regresije slučajnih šuma[13] bez i sa optimizacijom hiperparametrima je obavljen obukom nad trening skupom podataka, kao i predikcijom nad test skupom podataka, ispisan je takođe MSE, RMSE, R2 score. Korišćeni hiperparametri su: `n_estimators` (naznačava koji broj stabala odlučivanja će se uzeti u obzir, implicitno se uzima njih 100), `max_features`, `max_depth`, `max_leaf_nodes` (isto značenje kao i kod stabala odlučivanja).

Optimizacija hiperparametrima je obavljena na sličan način kao i kod stabala odlučivanja.

```
randomForestRegressor=RandomForestRegressor(n_estimators=10,random_state=0)
randomForestRegressor.fit(X_train, y_train)
predicted = randomForestRegressor.predict(X_test)
mse, rmse = evaluate(list(y_test), predicted, 'random forest')
print(f"R2 score: {r2_score(y_test, predicted)}")
print("-------------------")
# https://www.geeksforgeeks.org/random-forest-hyperparameter-tuning-in-
    python/
params={'n_estimators': [25, 50, 100, 150],
     'max_features': ['sqrt', 'log2', None],
     'max_depth': [3, 6, 9],
     'max_leaf_nodes': [3, 6, 9]
  }

modelGrid=GridSearchCV(RandomForestRegressor(),param_grid=params,cv=5)
modelGrid.fit(X_train,y_train)
modelBest = modelGrid.best_estimator_
predicted=modelBest.predict(X_test)
mse,rmse=evaluate(predicted, list(y_test), "Random Forest with
    hyperparameter optimization")
print(f"R2 score: {r2_score(y_test, predicted)}")
print('best params after grid search: ')
print(modelGrid.best_params_)
```

Implementacija 8: Postupak slučajnih šuma bez i sa optimizacijom hiperparametrima

3.6 Regresija potpornim vektorima (SVR)

Postupak regresije metoda potpornih vektora (SVR)[14] bez i sa optimizacijom hiperparametrima je obavljen obukom nad trening skupom podataka, kao i predikcijom nad test skupom podataka, ispisan je takođe MSE, RMSE, R2 score. Korišćeni hiperparametri su:

- `C` - implicitno je postavljeno na vrednost 0, a ovo je parametar regularizacije - naznačava jačinu regularizacije inverzno proporcionalno, a ona mora biti striktno pozitivna;
- `gamma` - implicitno je `'scale'`, primenjena je pri režimima kernela `'rbf', 'poly', 'sigmoid'`;
- `kernel` - implicitno `'rbf'` režim se uzima u obzir, ovim parametrom se uzima u obzir režim kernela kojim će baratati algoritam.

Optimizacija hiperparametrima je obavljena na sličan način kao i kod stabala odlučivanja.

```
supportVectorRegressor=SVR(kernel='rbf')
supportVectorRegressor.fit(X_train,y_train)
predicted = supportVectorRegressor.predict(X_test)
mse, rmse = evaluate(list(y_test), predicted, 'svr')
print(f"R2 score: {r2_score(y_test, predicted)}")
print("-------------------")
# https://www.geeksforgeeks.org/random-forest-hyperparameter-tuning-in-python/
params = {'C': [0.1, 10, 100],
              'gamma': [1, 0.01, 0.001],
              'kernel': ['linear', 'poly', 'rbf', 'sigmoid']}


modelGrid=GridSearchCV(SVR(),param_grid=params,cv=5)
modelGrid.fit(X_train,y_train)
modelBest = modelGrid.best_estimator_
predicted=modelBest.predict(X_test)
mse,rmse=evaluate(predicted, list(y_test), "Support vector regression with hyperparameter optimization")
print(f"R2 score: {r2_score(y_test, predicted)}")
print('best params after grid search: ')
print(modelGrid.best_params_)
```

Implementacija 9: Postupak regresije metoda potpornih vektora (SVR) bez i sa optimizacijom hiperparametrima

4 Rezultati

4.1 Jednostavna linearna regresija (SLR)

U izlazu 2. moguće je uočiti da je najbolji ishod regresije bio nad feature-om `median_income` sa MSE: 7274334668.63 i RMSE od 85289.71, dok R2 score za njega samo sračunat je bio oko 0.46.

```
Simple linear regresion over longitude
mean square error: 13249925560.75
root mean square error: 115108.32


Simple linear regresion over latitude
mean square error: 13054128998.76
root mean square error: 114254.67


Simple linear regresion over housing_median_age
mean square error: 13151138804.24
root mean square error: 114678.41


Simple linear regresion over total_rooms
mean square error: 13116182951.67
root mean square error: 114525.91


Simple linear regresion over total_bedrooms
mean square error: 13268375872.85
root mean square error: 115188.44


Simple linear regresion over population
mean square error: 13289199266.77
root mean square error: 115278.79


Simple linear regresion over households
mean square error: 13244660307.41
root mean square error: 115085.45


Simple linear regresion over median_income
mean square error: 7274334668.63
root mean square error: 85289.71
R2 score: 0.45277738375262455
```

Izlaz 2: SLR za sve features-e ponaosob

Data je slika 2. na kojoj je prikazan postupak regresije nad feature-om `median_income`.

4.2 Višestruka linearna regresija (MLR)

Dobijen ispis na izlaz 3. za primenjen algoritam MLR modela je takav da mu je MSE: 5180413707.33, RMSE: 71975.09, R2 score: 0.61.

```
Multiple linear regresion
mean square error: 5180413707.33
root mean square error: 71975.09

```

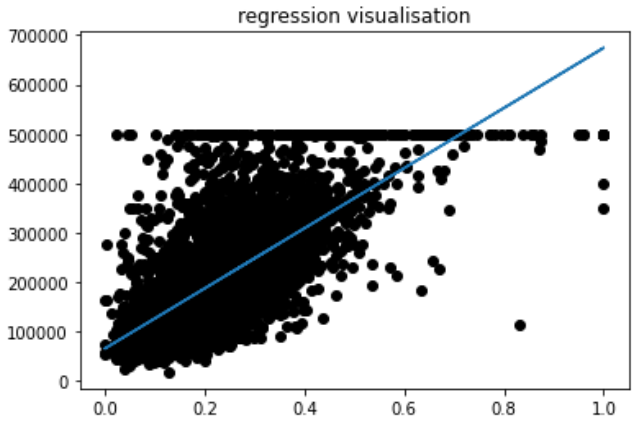

Slika 2: Jednostavna linearna regresija nad feature-om `median_income`

```
R2 score: 0.6102956942033559
```

Izlaz 3: MLR

Na slici 3. je prikazan grafik ishodujuće regresije.

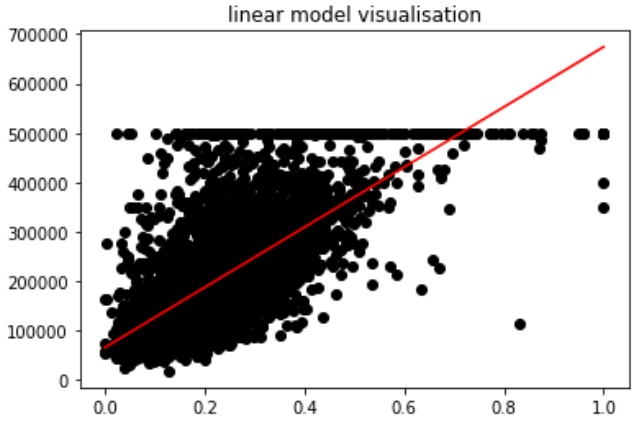

Slika 3: MLR grafik

4.3 Polinomijalna linearna regresija (PLR)

Dobijen izlaz 4. za primenjen algoritam PLR modela je takav da mu je MSE: 0.0, RMSE: 0.0, R2 score: -0.54.

```
    polynomial_regression
    mean square error: 0.0
    root mean square error: 0.0

    R2 score: -0.5451445244202564
```

Izlaz 4: PLR

Na slici 4. je prikazan grafik ishodujuće regresije, stepena 3, sagledajući, po mom mišljenju bolji za vizuelizaciju, feature `households`. Većina ostalih features-a ima sličan oblik pozicija uzoraka.

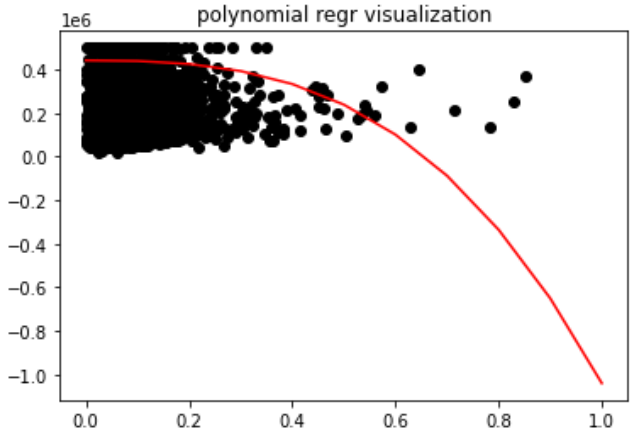

Slika 4: PLR grafik

4.4 Regresija stabla odlučivanja

Dobijen izlaz 5. za primenjen algoritam modela je takav da mu je MSE: 0.0, RMSE: 0.0, R2 score: -0.63.

```
decision tree
mean square error: 0.0
root mean square error: 0.0
R2 score: 0.6309696611415031
```

Izlaz 5: Stabla odlučivanja

Za najbolji moguć sastav hiperparametara:

- `splitter == 'best'`,
- `max_depth == 5`,
- `min_samples_leaf == 1`,
- `min_weight_fraction_leaf == 0.1`,
- `max_features == None`,
- `max_leaf_nodes == None`.

dobijen je ishodujući rezultat na izlazu 6. gde mere važe za MSE: 6567139517.78, RMSE: 81037.89, R2 score: 0.51.

```
decision tree with hyperparameter optimization
mean square error: 6567139517.78
root mean square error: 81037.89
R2 score: 0.5059771880336792
best params after grid search:
{'max_depth': 5, 'max_features': None, 'max_leaf_nodes': None, '
    min_samples_leaf': 1, 'min_weight_fraction_leaf': 0.1, 'splitter': 'best
    '}
```

Izlaz 6: Stabla odlučivanja sa optimizacijom hiperparametrima

4.5 Regresija slučajne šume

Dobijen izlaz 7. za primenjen algoritam modela je takav da mu je MSE: 0.0, RMSE: 0.0, R2 score: -0.79.

```
random forest
mean square error: 0.0
root mean square error: 0.0
R2 score: 0.7906854214130685
```

Izlaz 7: Slučajne šume

Za najbolji mogući sastav hiperparametara:

- `n_estimators == 150`,
- `max_depth == 9`,
- `min_samples_leaf == 1`,
- `max_features == None`,
- `max_leaf_nodes == 9`.

dobijen je ishodujući rezultat na izlazu 8. gde mere važe za MSE: 5766173566.8, RMSE: 75935.32, R2 score: 0.57.

```
Random Forest with hyperparameter optimization
mean square error: 5766173566.8
root mean square error: 75935.32
R2 score: 0.5662310398546941
best params after grid search:
{'max_depth': 9, 'max_features': None, 'max_leaf_nodes': 9, 'n_estimators':
    150}
```

Izlaz 8: Slučajne šume sa optimizacijom hiperparametrima

4.6 Regresija potpornim vektorima (SVR)

Dobijen izlaz 9. za primenjen algoritam modela je takav da mu je MSE: 0.0, RMSE: 0.0, R2 score: -0.05.

```
svr
mean square error: 0.0
root mean square error: 0.0
R2 score: -0.045590393753930814
```

Izlaz 9: SVR

Za najbolji mogući sastav hiperparametara:

- `C == 100`,
- `gamma == 1`,
- `kernel == 'poly'`.

dobijen je ishodujući rezultat na izlazu 10. gde mere važe za MSE: 8730005894.59, RMSE: 93434.5, R2 score: 0.34.

```
Support vector regression with hyperparameter optimization
mean square error: 8730005894.59
root mean square error: 93434.5
R2 score: 0.3432723564267346
best params after grid search:
{'C': 100, 'gamma': 1, 'kernel': 'poly'}
```

Izlaz 10: SVR sa optimizacijom hiperparametrima

5 Zaključak

Predstavljeni slučajevi tačnosti za svaki model regresije na tabeli 1. može se uočiti da je najbolji model **MLR**. Sa druge strane, je najgori slučajne šume.

I moguće je uočiti da je pospešujuć efekat optimizacija hiperparametrima nad modelima nad kojima je bio primenjivan.

Klasifikator	**MSE**	**RMSE**	**R2 score**
SLR nad `median_income`	274334668.63	85289.71	0.46
MLR	5180413707.33	71975.09	0.61
PLR	0.0	0.0	-0.54
Stablo odlučivanja	0.0	0.0	-0.63
Stablo odlučivanja sa optimizacijom hiperparametrima	567139517.78	81037.89	0.51
Slučajne šume	0.0	0.0	-0.79
Slučajne šume sa optimizacijom hiperparametrima	766173566.8	75935.32	0.57
SVR	0.0	0.0	-0.05
SVR sa optimizacijom hiperparametrima	730005894.59	93434.5	0.34

Tabela 1: Prikaz tačnosti klasifikatora sa i bez primene optimizacije hiperparametara.

Literatura

[1] California Housing (EDA + linear regression), https://www.kaggle.com/code/mohamedkhaledelsafty/california-housing-eda-linear-regression, Datum poslednjeg pristupa: 3. maj 2024.

[2] Ž. Simić, (2024), "Teorijski izveštaj o regresionim algoritmima sa nadgledanim učenjem", Univerzitet u Kragujevcu

[3] DataFrame, https://pandas.pydata.org/docs/reference/frame.html, Datum poslednjeg pristupa: 3. maj 2024.

[4] sklearn.preprocessing.LabelEncoder, https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.LabelEncoder.html, Datum poslednjeg pristupa: 3. maj 2024.

[5] When should I use StandardScaler and when MinMaxScaler?, https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.LabelEncoder.html, Datum poslednjeg pristupa: 3. maj 2024.

[6] sklearn.model_selection.train_test_split, https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html, Datum poslednjeg pristupa: 3. maj 2024.

[7] seaborn.pairplot, https://seaborn.pydata.org/generated/seaborn.pairplot.html, Datum poslednjeg pristupa: 3. maj 2024.

[8] seaborn.displot, https://seaborn.pydata.org/generated/seaborn.displot.html, Datum poslednjeg pristupa: 3. maj 2024.

[9] sklearn.linear_model.LogisticRegression, https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html#sklearn.linear_model.LogisticRegression, Datum poslednjeg pristupa: 3. maj 2024.

[10] sklearn.preprocessing.PolynomialFeatures, https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.PolynomialFeatures.html, Datum poslednjeg pristupa: 3. maj 2024.

[11] sklearn.tree.DecisionTreeRegressor, https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeRegressor.html#sklearn.tree.DecisionTreeRegressor, Datum poslednjeg pristupa: 3. maj 2024.

[12] sklearn.model_selection.GridSearchCV, https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html, Datum poslednjeg pristupa: 3. maj 2024.

[13] sklearn.ensemble.RandomForestRegressor, https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestRegressor.html, Datum poslednjeg pristupa: 3. maj 2024.

[14] sklearn.svm.SVR, https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVR.html#sklearn.svm.SVR, Datum poslednjeg pristupa: 3. maj 2024.